


1. EDA



1. EDA

- EDA(탐색적 데이터 분석) : 주어진 데이터를 시각화하고, 통계적인 요약을 통해
- 데이터의 특성과 구조를 이해하는 과정

1. 데이터의 구조를 이해함

2. 데이터의 분포를 확인함

3. 이상치와 결측치를 탐지하여 적절한 대응 방식을 적용함


2. 결측치와 이상치

- 결측치 : 데이터셋에서 값이 누락되어 있는 경우
- 단순 대체법 : 결측치가 있는 열을 삭제함
- 평균 대체법 : 결측치를 해당 특징의 평균값으로 대체함

【단순대체법 예시】





【평균 대체법 예시】



2. 결측치와 이상치

- ESD 방식 : 각 데이터가 표준편차 기준에서 평균으로부터 얼마나 떨어져 있는지를 계산하여,
특정 임계값을 초과하는 값을 이상치로 간주
- 사분위수 활용 방식 : $Q1 - 1.5 * IQR \leq X \leq Q3 + 1.5 * IQR$ 범위를 벗어나는 데이터를 이상치로 간주

【ESD】



2. 결측치와 이상치

1	5	3	1	5	5	9	4	7	6	4
---	---	---	---	---	---	---	---	---	---	---

다음 자료의 사분위수 범위(IQR)를 구하세요.

개


3. EDA의 최종 목표

- 데이터의 분포를 확인하여 가설을 세움
- 데이터의 이상치, 결측치에 대해 대처
- 머신러닝 알고리즘에 데이터를 입력할 수 있도록 데이터를 변환



0. 머신러닝


- 기계 학습 : 기계가 일일이 코드로 명시하지 않은 동작을 데이터로부터 학습하여 실행할 수 있도록 하는 알고리즘을 개발하는 연구 분야. by 아서 사무엘, 1959
- 기계 학습의 핵심은 표현(representation) 과 일반화(Generalization)이다.



0. 머신러닝


지도 학습

- 레이블링 된 데이터
- 직접 피드백
- 분류, 회귀



비지도 학습

- 레이블링 되지 않은 데이터
- 피드백이 없음
- 군집화, 차원 축소



강화학습


- 결정 과정에서 학습하는 에이전트
- 행동에 대한 보상
- 로봇틱스, 시뮬레이션




2. 분류(classification)

- 분류 : 데이터(X)를 기반으로, 새로운 데이터의 **범주형 클래스 라벨(Y)**을 예측하는 것이 목표
주로 두 개 이상의 클래스 라벨을 가지고 있다.
- 예시 :
 - 스팸 메일의 분류(스팸 메일 vs 스팸 메일이 아닌 메일)
 - 손글씨 분류(0에서 9까지 손으로 쓴 글자를 분류)

- 이진분류(Binary classification)




다중분류(Multi-class classification)




3. 회귀(regression)

- 회귀 : 데이터(X)를 기반으로, 새로운 **데이터의 값(Y)**을 예측하는 것이 목표
- 예시 :
 - 학생들의 공부 시간을 바탕으로 시험 점수 예측
 - 집의 다양한 특징들을 바탕으로 집값 예측

- 이진분류(Binary classification)



- 선형 회귀(Linear Regression)



2. 군집화(clustering)

- **군집 분석** : 같은 군집이 다른 군집보다 더 비슷하도록, **데이터에 있는 자연스러운 그룹을 찾는 것**
정답을 모르는(라벨이 없는) 데이터 안에 숨겨진 군집을 찾을 수 있음
- **종류** :
 - **중심 기반**, **밀도 기반**, **배포 기반**, **계층 기반** 클러스터링 등




그림 1: 중심 기반 클러스터링의 예




그림 2: 밀도 기반 클러스터링의 예

3. 차원축소(Dimension reduction)

- 차원 축소 : 많은 특성 변수(x, feature)로 구성된 다차원 데이터셋의 차원을 줄여 새로운 저차원 데이터셋을 생성하는 과정
 - 고차원 데이터를 저차원 데이터로 변환하여 활용 및 이해가 용이하도록 함
 - 원본 데이터의 특성을 최대한 유지하도록 함






Fig. 3: An example for the one-to one DR.



머신러닝 알고리즘



scikit-learn
algorithm cheat-sheet

Back

알고리즘들

번호	알고리즘 이름	분류	회귀	차원 축소	군집화
1	선형회귀(Linear Regression)		●		
2	서포트 벡터 머신(Support Vector Machine)	●	●		
3	나이브 베이즈 분류(Naïve-Bayes)	●			
4	주성분분석(PCA)			●	
5	T-분포 확률적 임베딩(t-SNE)			●	
6	K-최근접 이웃 알고리즘 (K-nearest Neighbors algorithm)	●	●		
7	K-평균 알고리즘 (K-means algorithm)				●
8	DBScan				●
9	의사결정나무(decision tree)	●	●		
10	랜덤 포레스트(random forest)	●	●		
11	Bagging Classifier/Regressor	●	●		
12	Gradient Boosting Machines(GBM)	●	●		

K-최근접 이웃 알고리즘



주변 K개 데이터 포인트와의 거리를 계산하여, 다수결로 더 가까운 데이터로 분류/회귀

주어진 데이터에 대해 주변 k개 데이터와의 유클리드 거리를 계산

- 장점 : 구현이 쉽고, 데이터 포인트가 비교적 섞여 있는 경우에도 안정적으로 분류 가능
- 단점 : 리소스의 소모가 크고 과적합에 취약

의사결정 나무

Decision tree trained on all the iris features





조건 분기에 따라 학습 데이터를 나누어 분류

불순도를 최소화하도록 데이터를 나누며 분류 수행

- 장점 : 직관적인 형태로 모델 이해 가능, 스케일링 불필요, 비선형 데이터에 대해 강건
- 단점 : 과적합 가능성이 높음, 데이터 변화에 민감
- 분류는 지니 계수를 기준으로, 회귀의 경우 MSE를 기준으로 노드를 나누어 분류/회귀 모두 사용
- 불순도 지표 : 지니 계수

선형회귀

$$MSE = (1/n) \sum_{i=1}^n (y_i - \hat{y}_i)^2$$






데이터의 특징들(x, features)을 설명할 수 있는 하나의 선(수식)을 찾아내는 것

단순선형회귀, 다중선형회귀(x가 여러 개), 다항회귀(x의 차수가 2차 이상) 등으로 나누어짐

- 장점 : 단순하고 해석이 용이함, 다양한 케이스에 적용해 볼 수 있음
- 단점 : 비선형성 데이터에 적용 어려움, 지나친 단순성으로 인한 과소적합 우려, 이상치에 대한 민감성
- 주의할 점 : 사용되는 특징들 사이에 자기상관성(시계열)이나 다중 공선성(다중회귀)이 있지 않은지를 확인해봐야 함
- 오차 : 평균제곱오차(MSE, Mean Squared Error)

서포트 벡터 머신



데이터의 특징들(x , features) 중 가능한 한 먼 결정 경계를 찾아내는 것

마진(결정 경계에 가장 가까운 점과 결정 경계 사이의 거리)의 최대화

- 최적의 초평면 찾기 -> 초평면에 가장 가까운 데이터를 '서포트 벡터'로 식별 -> 서포트벡터를 기준으로 결정경계 구축
- 장점 : 일반화 능력(다양한 케이스에 적용 가능)과 높은 성능을 보여줌
- 단점 : 파라미터를 어떻게 세팅하느냐에 따라 결과의 변동성이 큼, 모델 해석이 어려움
- 주의할 점 : 소프트마진(데이터를 완전히 분류하기 어려울 때 일부 데이터가 마진 안에 포함되는 경우)가 발생할 수 있음




K-means clustering

K-평균 군집화

- ① 정의 : 데이터를 K개의 군집으로 만드는 방법.
- ② 키워드 : 센트로이드(centroid) : 군집의 중심이 되는, 평균값을 갖는 데이터 포인트
- ③ 장점 : 작은 데이터셋에서 잘 작동한다.
- ④ 단점 : K의 개수를 사람이 직접 지정해야 하는데, 올바른 수의 K를 찾아내기 쉽지 않다.
- ⑤ 특징 :
 - ① 반드시 K개의 군집을 지정해주어야 함
 - ② 클러스터가 중첩되어 있지 않음
 - ③ 클러스터가 계층적이지 않음
- ⑥ 지정 옵션
 - ① K의 수
 - ② 센트로이드 이동 횟수

$$\sqrt{(x_1 - x_2)^2 + (y_1 - y_2)^2}$$







K-means clustering

■ 실행


- K개의 초기 중심 설정
- 각 데이터 포인트를 가장 가까운 중심점에 할당(유클리드 거리 계산)
- 각 클러스터 안의 모든 데이터 포인트의 평균 좌표를 계산하여, 새 클러스터 중심점으로 옮김
- 새 클러스터 중심점에 대해, 다시 각 데이터 포인트를 가장 가까운 중심점에 할당
- 각 클러스터 안의 모든 데이터 포인트의 평균 좌표를 계산하여...
- 중심점 변동이 없을 때 까지 이 행위를 반복(혹은, 정해진 반복 횟수를 채울 때 까지)

$$\sqrt{(x_1 - x_2)^2 + (y_1 - y_2)^2}$$



K-means clustering


WCSS : 각 점과 클러스터의 중심 사이의 거리 제곱의 합




K-means clustering

실루엣 계수 : 군집 내 샘플들이 얼마나 조밀하게(잘) 모여 있는지를 측정하는 도구

Silhouette Coefficient





- $a(i)$ = 같은 클러스터와의 평균 거리
- $b(i)$ = 가장 가까운 다른 클러스터와의 평균 거리
- 우리가 원하는 것 $a(i) < b(i)$
- $S(i) = \max\left(\frac{b(i) - a(i)}{b(i)}, \frac{a(i) - b(i)}{a(i)}\right)$ 중 더 큰 값
- 최선의 경우 : $a(i)$ 가 0에 가깝고 $b(i)$ 가 무한에 가까움
- 최악의 경우 : $a(i)$ 가 무한에 가깝고 $b(i)$ 가 0에 가까움
- -1과 1 사이의 값을 가짐






DBScan

- ① 정의 : center point를 기반으로, 정해진 반경 내의 포인트를 군집에 포함시켜 데이터를 군집화
- ② 키워드 :
 - ① Core point: 주변 반경에 정해진 수 이상의 이웃을 가지고 있는 데이터
 - ② Border point : 이웃이 적지만 다른 core point 의 반경 안에 있는 데이터
 - ③ Noise point : Core point와 Border point가 아닌 데이터
 - ④ Epsilon : 반경(범위)의 크기
 - ⑤ 최소 이웃의 수
- ③ 장점 :
 - ① 복잡한 모양의 클러스터에 대해 좋은 성능을 보임
 - ② 모든 샘플을 클러스터에 할당하지 않고, 노이즈 샘플을 구분할 수 있음
- ④ 단점 :
 - ① 차원의 저주(고차원에서 알고리즘을 수행할 때, 실행이 까다로워지는 것)

DBScan



DBScan



PCA

① 실행 순서 :

- ① 데이터 정규화 -> 각 변수의 값의 범위가 서로 다르므로, 데이터의 평균을 0으로 맞추고 스케일을 동일하게 하는 정규화를 수행
- ② 공분산 행렬 계산 -> 변수 간의 공분산을 계산하여, 변수 간의 관계를 파악함
- ③ 공분산 행렬을 분해하여 고유값(분산의 크기), 고유벡터(주성분의 방향) 계산
- ④ 주성분 선택 -> 가장 큰 고유값을 갖는 n개의 고유벡터 선택
- ⑤ 데이터 변환 -> 선택한 주성분을 축으로 하여 새 좌표계에 데이터를 투영


② 장점 :

- ① 노이즈 제거
- ② 속도 향상

③ 단점 :


- ① 정보 손실

PCA




공분산은 두 데이터가 어떤 관계를 갖는지 나타낸다. 음이면 반비례, 양이면 정비례를 의미한다.

PCA



어떠한 벡터에 행렬 연산을 취하면, 원본 벡터와는 다른 방향과 크기를 가진 벡터가 나온다.

$$\begin{bmatrix} 1 \\ 1 \end{bmatrix} \quad \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix}$$







그런데, 어떤 벡터와 행렬은 연산을 취해도 '크기'만 변하고 방향은 그대로일 수도 있다. ($Ax = \lambda x$)




고유값 : 임의의 $n \times n$ 정방행렬 A 에 대하여, 0이 아닌 (솔루션)벡터가 존재한다면 숫자 λ 는 행렬 A 의 고유값이라고 할 수 있다.

고유벡터 : 고유벡터 x 는 행렬 A 에 곱해졌을 때 방향이 변하지 않는 특별한 벡터


고유값과 고유벡터의 의미 : 고유벡터는 데이터의 분산이 가장 큰 방향, 고유값은 주성분이 설명하는 분산의 크기



$$d_1^2 + d_2^2 + d_3^2 + d_4^2 + d_5^2 + d_6^2 = \text{sum of squared distances} = \text{SS}(\text{distances})$$



...then we use the projected points to find where the samples go in the PCA plot.



T-SNE

① 실행순서 :

- ① 고차원 공간에서 데이터 포인트 간의 유사성 계산(정규 분포)
- ② 저차원 공간에서 데이터 포인트 간의 유사성 계산(t-분포)
- ③ (KL-발산을 지표로 하여 차이 측정) 저차원 공간을 조정하며 유사성의 차이를 최소화
- ④ (경사하강법을 통한) 최적화 과정

② 장점 :


- ① 비선형 차원 축소(복잡한 데이터 패턴에도 강함)
- ② 지역적 유사성 보존 : 고차원과 저차원 모두를 고려하여 최적화

③ 단점 :

- ① 매개변수에 민감성
- ② 대규모 데이터에서 속도가 느림




성능 개선 : 검증과 앙상블, 하이퍼 파라미터 튜닝



검증 : 데이터셋을 나누어 확인한다

- ① 홀드아웃 : 초기 데이터셋을 훈련 데이터셋과 검증 데이터셋으로 나뉘, 훈련 데이터셋은 훈련에 사용하고 검증 데이터셋은 검증에 사용하는 것
- ② 왜 검증 데이터셋을 나누어 사용하는가?
 - ① 모델을 한 번 훈련시키는 것으로는 적합한 하이퍼파라미터를 가진 모델을 찾을 수 없음
 - ② -> 같은 테스트셋을 가지고 훈련을 계속 반복하게 됨 -> 테스트셋도 훈련 셋처럼 되어 버림

주의해야 할 점 : 검증 셋을 어떤 방법으로 나누었느냐에 따라, 성능 추정에 민감하게 반응할 수 있음



1. 교차검증

① K-Fold 교차검증(K겹 교차검증) :

훈련 데이터셋을 K개의 폴드로 랜덤하게 나누어, K-1개는 훈련에 사용하고 1개는 검증에 사용하는 것이 과정을 K번 반복하여, K개의 모델과 성능 추정을 얻는다. (K개의 모델을 평균 내어 성능을 추정)

② 특징

① 중복을 허용하지 않는 샘플링 기법(K에서 데이터셋이 서로 겹치지 않음)

② 모든 테스트 폴드가 중첩되지 않음

③ 권장

① 작은 데이터셋을 사용한다면

폴드 개수를 늘리는 것이 좋다.


(단, k값이 너무 커지면 실행 시간이 늘어나고, 적게 나누는 것과 비슷한 결과를 낼 수도 있다.)

K-fold 교차검증

Round 1	training set	training set	training set	test set
Round 2	training set	training set	test set	training set
Round 3	training set	test set	training set	training set
Round 4	test set	training set	training set	training set

2. 앙상블


- ① 앙상블 기법 : 여러 개의 분류기를 하나의 분류기로 연결하여, 개별 분류기보다 좋은 일반화 성능을 달성하는 기법
- ② 장점 : 여러 개의 약한 학습기가 편향과 분산을 낮추어 더 나은 성능을 달성함




▲ 그림 7-2 일반적인 앙상블 방법

2. 앙상블

배깅



부스팅





3. 하이퍼 파라미터 튜닝

① 하이퍼 파라미터(hyperparameter) :

사용자가 따로 설정하여 훈련할 수 있는 학습 알고리즘의 ‘옵션’

① 그리드 서치(Grid search) : 하이퍼파라미터를 격자 모양으로, 약간씩 변경하며 최적화하는 기법

② 랜덤 서치(Random search) : 하이퍼파라미터를 랜덤으로 변경하며 최적화하는 기법





빅데이터 분석과정

1. 데이터 수집 - 공공데이터_csv, json >> dict(api)
2. 데이터 불러오기 import , from sklearn
 - 훈련용 데이터, 평가용 데이터(새로운 데이터 간주)
 - 홀드아웃(평가용 데이터는 검증용이니깐)
3. 데이터 살펴보기 raw >> raw.copy >> df >> df.head >> shape >> info (결측치-notnull, 데이터타입 dtypes), describe()
4. 데이터 전처리-정규화(min-max scaler 0-1), 표준정규화(표준화)
5. 데이터 탐색(EDA) : 데이터시각화, matplotlib.pyplot, seaborn
6. 모델링 : 회귀분석, 로지스틱회귀,....
7. 분석 수행 y_pred(예측) << train_x (fit 과정)
8. 데이터 시각화
9. 모델 간 성능 비교